

Projet :

# Introduction à la reconnaissance des formes

## Étude et Comparaison des Méthodes de Classification

Par : Bouadi Sabrina

Année universitaire : 2024/2025

## Table des Matières

<b>1. Introduction</b>	3
1.1 Contexte et Objectif du projet	
1.2 Présentation de la Base de Données BDshape	
1.3 Approfondissement des Méthodologies de Reconnaissance des Formes	
1.4 Introduction aux Méthodes de Classification	
1.5 Objectif Principal	
<b>2. Méthodologie</b>	5
2.1 Méthodes de Classification	
2.2.1 Méthode des k-plus-proches voisins (k-NN)	
2.2.1.1 Principes Mathématiques	
2.2.1.2 Mécanismes et efficacité	
2.2.1.3 Avantages, limites et applications	
2.2.2 Méthode des k-moyennes (k-means)	
2.2.2.1 Principes Mathématiques	
2.2.2.2 Mécanismes et efficacité	
2.2.2.3 Avantages, limites et applications	
2.2.3 Comparaison et choix entre k-NN et k-means	
2.2.4 Conclusion	
<b>3. Analyse des courbes</b>	8
○ Courbes de Précision/Rappel	
<b>4. Étude Expérimentale</b>	9
4.1 Comparaison des Résultats pour 10 Classes et 18 Classes	
4.2 Comparaison des Méthodes selon le Temps d'Exécution et les Distances	
<b>5. Améliorations et Perspectives</b>	
5.1 Améliorations pour k-means	
5.1.1 K-means++ pour l'Initialisation des Centroids	
5.2 Exploration de Nouvelles Méthodes	
5.2.1 Réseaux de Neurones et Deep Learning	
5.2.2 Support Vector Machines (SVM)	
5.2.3 Clustering Hiérarchique	
<b>6. Conclusion</b>	12

# 1 Introduction

## 1.1 Contexte et Objectif du projet

La reconnaissance des formes est un domaine clé de l'informatique, utilisé dans des applications variées comme la vision par ordinateur, l'identification biométrique, ou encore la robotique. Elle consiste à identifier et classer des objets en fonction de leurs caractéristiques visuelles ou structurelles. Ce projet, issu du cursus d'Introduction à la reconnaissance des formes, vise à explorer de manière exhaustive les approches classiques de reconnaissance des formes. Il met ces approches à l'épreuve contre les défis réalistes présentés par la base de données BDshape, avec pour objectif d'évaluer et comparer ces méthodes en termes de précision, de robustesse et d'efficacité dans le traitement de données complexes.

## 1.2 Présentation de la Base de Données BDshape

La base de données utilisée, *SharvitB2*, est composée de 18 classes d'objets (oiseau, clé, tortue, etc.), chacune comprenant 12 échantillons. Ces échantillons présentent des variations telles que des déformations ou des orientations différentes. Chaque image est stockée au format .pgm et nommée selon le format SxxNyyy.pgm, où Sxx désigne la classe et Nyyy l'échantillon.

Les fichiers .pgm sont utilisés pour la visualisation, tandis que des représentations caractéristiques (vecteurs) ont été générées à l'aide de cinq descripteurs classiques (**E34**, **ART**, **ZRK**, **GFD**, et **YNG**)

## 1.3 Approfondissement des Méthodologies de Reconnaissance des Formes :

La reconnaissance des formes s'appuie sur l'extraction de caractéristiques pertinentes, permettant de représenter efficacement les objets à analyser. Dans ce projet, cinq méthodes de descripteurs classiques ont été utilisées pour extraire ces caractéristiques à partir des images binaires de la base *SharvitB2* : **E34**, **ART**, **ZRK**, **GFD**, et **YNG**.

Pour ce projet, cinq méthodes classiques de reconnaissance des formes ont été utilisées pour analyser les images binaires de la base *SharvitB2*.

1. **E34 (Mesure du Degré d'Ellipticité)** : Évalue la proximité d'une forme à une ellipse parfaite en analysant les segments radiaux issus de son centre de masse, basée sur la géométrie analytique.
2. **ART (Transformée Radiale Angulaire)** : Analyse les variations angulaires et radiales pour capturer la structure globale des formes, robuste aux rotations.
3. **ZRK (Moments de Zernike)** : Utilise des polynômes complexes pour fournir des descripteurs invariants aux rotations et précis pour les comparaisons.
4. **GFD (Descripteur de Fourier Générique)** : Exploite une transformée discrète polaire pour analyser les fréquences radiales et angulaires, efficace face aux variations de taille et position.
5. **YNG (Signature de Yang)** : Décrit les formes à partir de leur squelette, offrant une représentation compacte adaptée aux formes complexes.

Ces cinq méthodes complémentaires permettent une caractérisation variée des formes, essentielle pour évaluer et comparer les performances des classifieurs

#### **1.4 Introduction aux Méthodes de Classification :**

En complément des méthodes de reconnaissance des formes, ce projet envisage également l'utilisation de techniques de classification avancées, telles que les k-plus-proches voisins (knn) et les algorithmes de clustering comme les nuées dynamiques (k-means). Ces méthodes seront explorées pour leur potentiel à classer efficacement les formes analysées. Leur application, efficacité, et intégration avec les méthodes de reconnaissance des formes seront examinées en détail dans les sections ultérieures du rapport.

#### **1.5 Objectif Principal :**

Ce projet a pour ambition de fournir une évaluation comparative des méthodes conventionnelles de reconnaissance des formes dans un contexte moderne. Notre objectif est d'enrichir notre compréhension de ces techniques et d'explorer des améliorations potentielles basées sur les résultats obtenus. Ce travail représente une opportunité précieuse d'appliquer nos connaissances théoriques à un problème concret, enrichissant ainsi notre expérience académique et professionnelle dans le domaine de l'informatique.

## 2 Méthodologie

### 2.1 Méthodes de Classification

Cette partie du rapport se concentre sur l'examen approfondi des méthodes des k-moyennes et des k-plus Proches Voisins (knn), deux techniques fondamentales en apprentissage automatique. Notre objectif est de fournir une compréhension claire et détaillée de ces méthodes, soulignant leur fonctionnement, leurs avantages, et leurs limites. Cette analyse vise à éclairer les praticiens sur l'utilisation efficace et judicieuse de ces outils dans divers scénarios d'analyse de données.

#### 2.2.1 Méthode des k-plus-proches voisins (knn)

##### 2.2.1.1 Principes Mathématiques La méthode des k-plus-proches voisins

est une technique de classification et de régression supervisée. La classe d'un nouveau point de données est déterminée par la majorité des classes de ses k voisins les plus proches. La distance entre les points de données est souvent calculée à l'aide de la

distance euclidienne, définie comme:  $d(x_i, x_j) = \sqrt{\sum_{k=1}^n (x_{ik} - x_{jk})^2}$ ,

où  $x_i$  et  $x_j$  sont deux points de données et  $n$  est le nombre de caractéristiques

##### 2.2.1.2 Mécanismes et efficacité

L'algorithme des k-plus-proches voisins (k-NN) calcule la distance entre le point de test et tous les points de l'ensemble d'apprentissage, puis sélectionne les k points les plus proches pour déterminer la classe de sortie. Pour la classification, la classe la plus fréquente parmi les k voisins est choisie. Cette méthode est efficace pour les données où la proximité reflète une similarité réelle et est appréciée pour sa simplicité et sa nature non paramétrique

##### 2.2.1.3 Avantages, limites et applications

La méthode des k-plus proches voisins (k-NN) est prisée pour sa simplicité et sa flexibilité, ce qui la rend adaptée à de nombreuses applications, comme la reconnaissance de formes et la recherche médicale. Sa principale force est de réaliser des classifications précises en se basant sur les voisins les plus proches. Par exemple, en reconnaissance de formes, elle peut identifier la catégorie d'une image en la

comparant à des images étiquetées, et dans les systèmes de recommandation, elle peut suggérer des produits ou des films en trouvant des utilisateurs aux goûts similaires. En recherche médicale, elle aide à classifier des tumeurs en analysant les cas proches.

Cependant, la méthode présente des limites. Elle est sensible à la dimensionnalité des données, ce qui peut réduire son efficacité dans des espaces de haute dimension, un phénomène appelé "malédiction de la dimensionnalité". De plus, elle nécessite une grande mémoire pour stocker l'ensemble des données d'apprentissage, ce qui pose problème pour des ensembles volumineux. La performance de k-NN dépend également du choix du paramètre k, qui doit être bien ajusté pour éviter le surajustement ou le sous-ajustement.

## **2.2.2 Méthode des k-moyennes (kmeans)**

### **2.2.2.1 Principes Mathématiques**

La méthode des k-moyennes est une technique de clustering non supervisée qui vise à partitionner un ensemble de données en k clusters distincts. L'objectif est de minimiser la variance intra-cluster, ce qui est mathématiquement exprimé par la somme des carrés des distances entre les points de données et le centroïde de leur cluster respectif. La fonction de coût est définie comme:

$$J = \sum_{i=1}^K \sum_{x \in S_i} \|x - \mu_i\|^2$$
, où  $S_i$  est le i-ème cluster,  $x$  est un point de données dans  $S_i$ , et  $\mu_i$  est le centroïde du i-ème cluster.

### **2.2.2.2 Mécanismes et efficacité**

L'algorithme des k-moyennes commence par sélectionner aléatoirement k points comme centroïdes initiaux. Chaque point de données est ensuite assigné au cluster dont le centroïde est le plus proche selon la distance euclidienne. Les centroïdes sont recalculés à chaque itération comme la moyenne des points assignés à chaque cluster. L'algorithme répète ces étapes jusqu'à ce que les centroïdes se stabilisent, indiquant ainsi la convergence. Il optimise une fonction de coût en réduisant la variance au sein des clusters, garantissant ainsi des groupes compacts et bien séparés, à condition que les données soient adaptées à ce type de regroupement.

### 2.2.2.3 Avantages, limites et applications

La méthode des k-moyennes est simple et efficace, idéale pour traiter de grands ensembles de données et regrouper des points similaires. Elle est utilisée dans des domaines comme la segmentation de marché, la bioinformatique pour le regroupement de données génétiques, et l'analyse de documents pour classifier des textes par thème. Cependant, elle est sensible aux choix des centroïdes initiaux, ce qui peut influencer la qualité des clusters. De plus, elle n'est pas efficace avec des clusters non sphériques ou de tailles variées, car elle privilégie des formations sphériques. Ces points doivent être pris en compte pour utiliser efficacement l'algorithme des k-moyennes

### 2.2.3 Comparaison et choix entre knn et kmeans

**k-NN** est un algorithme de classification supervisée qui évalue la classe d'un échantillon en se basant sur ses voisins les plus proches. Il est adapté aux données étiquetées où les relations de proximité sont importantes, mais il devient lent avec de grands ensembles de données.

**k-means**, quant à lui, est un algorithme de clustering non supervisé utilisé pour regrouper des points similaires en clusters. Il est efficace pour analyser de grands ensembles de données et découvrir des structures naturelles, mais il est sensible aux valeurs aberrantes et dépend de l'initialisation des centroïdes.

**k-NN** offre une meilleure précision pour des tâches de classification lorsque les données sont de taille modérée, tandis que **k-means** est plus rapide et efficace pour la segmentation de données volumineuses, mais il peut avoir des problèmes avec des données non sphériques ou bruitées. Le choix entre les deux dépend de l'objectif (classification ou regroupement) et des caractéristiques des données.

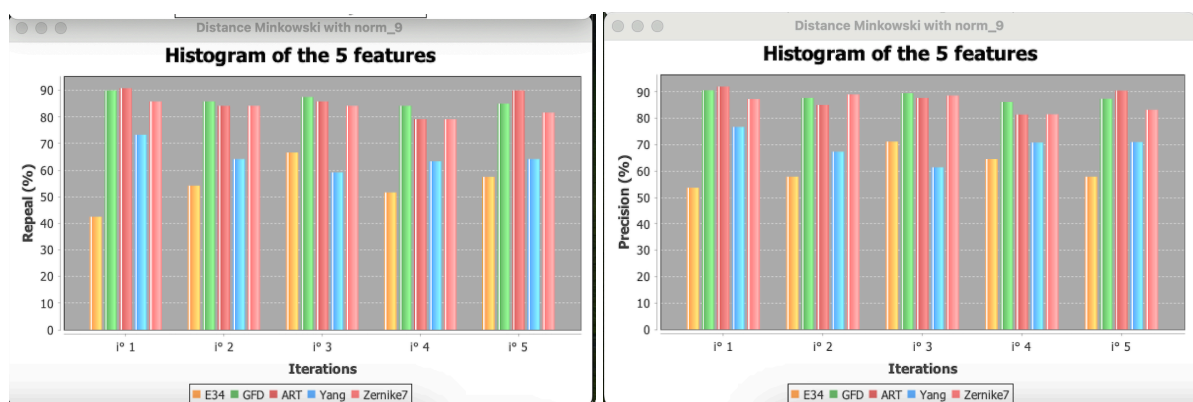
### 2.2.4 Conclusion

En somme, la décision d'utiliser la k-moyennes ou la knn doit être prise en considération de la nature des données, de l'objectif de l'analyse et des contraintes computationnelles. Comprendre les points forts et les limites de chaque méthode permet une utilisation plus éclairée et efficace, contribuant ainsi à la réussite des projets d'analyse de données. La maîtrise de ces méthodes est donc essentielle pour les praticiens souhaitant exploiter pleinement le potentiel de l'apprentissage automatique dans divers contextes d'application.

## 4 Analyse des courbes

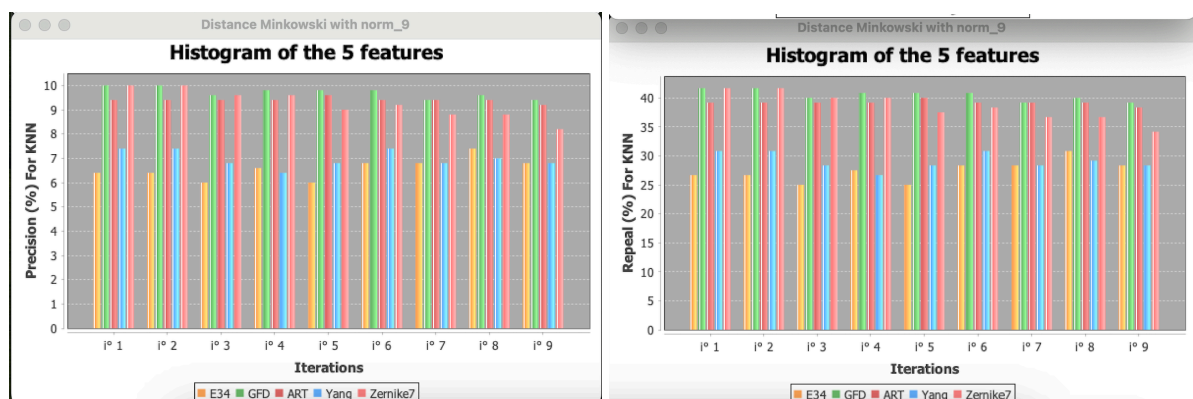
### 4.1 Courbes de Précision/Rappel

Des courbes de précision/rappel ont été générées pour les 10 classes, permettant de comparer l'efficacité de chaque approche en termes de précision et de rappel. Ci dessous, les résultats retournés par l'implémentation K-means avec 5 itérations



les valeurs pour toutes les méthodes sont un peu variantes mais reste approximativement les même, pour le cas de K means on remarque que GFD , ART et Zernike7 sont les méthodes avec les meilleurs taux très loin devant E34

Ci-dessous, les courbes de précision et rappel de l'approche Knn de 1 à 9 voisins.



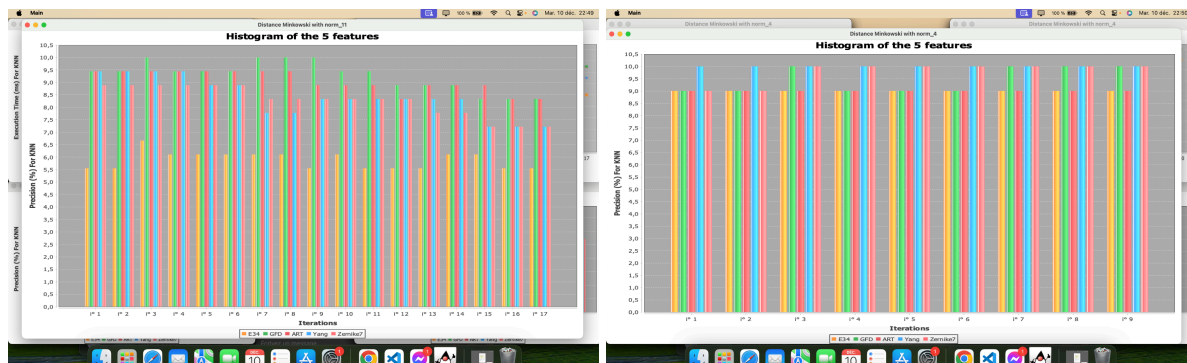


L'approche Knn similairement contient des valeurs assez constantes pour chaque méthode respective mais reste avec des résultats moins concluants que K Means surtout pour sa précision.

## 5. Étude Expérimentale


### 5.1 Comparaison des Résultats pour 10 Classes et 18 Classes

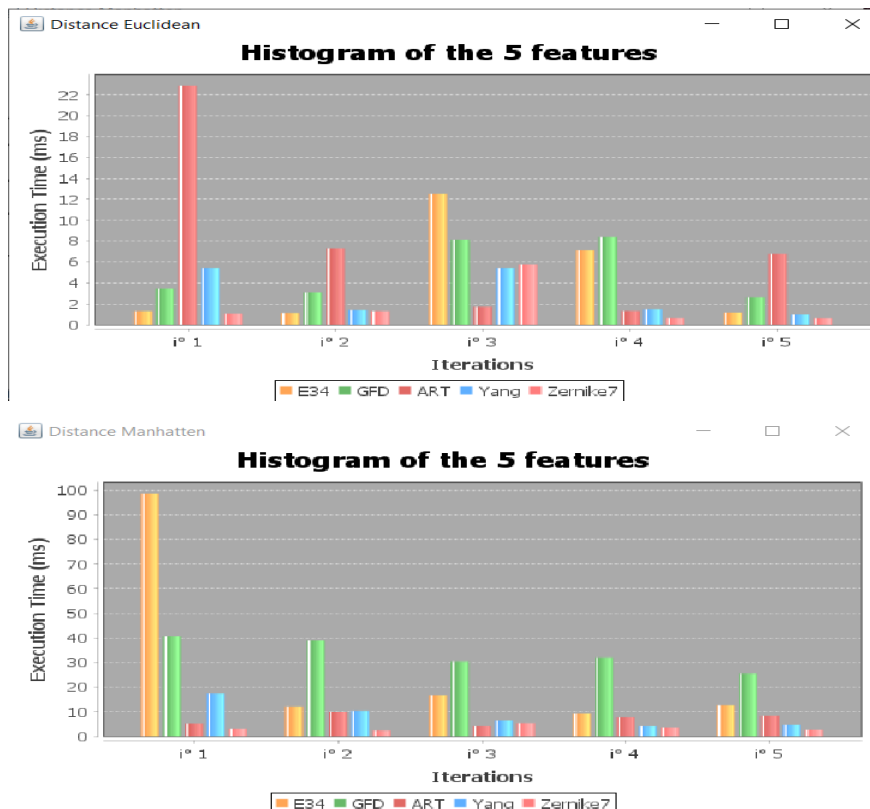
En comparant les taux de reconnaissance des 10 premières classes avec ceux des 18 classes, il a été observé que la complexité accrue avec toutes les classes a affecté certaines méthodes, tandis que d'autres ont maintenu des performances similaires comme GFD et ART ce qui peut s'expliquer par leur petit nombre de dimensions face aux autres méthodes. appeler également "malédiction de la dimensionnalité" comme évoqué précédemment.



### 5.2 Comparaison des Méthodes selon le Temps d'Exécution et les Distances

L'analyse des performances des méthodes de reconnaissance en fonction des temps d'exécution et des métriques de distance (euclidienne, Manhattan, Minkowski) révèle des différences notables dans leur comportement





## Temps d'Exécution

- **E34** s'est avérée la méthode la plus rapide lors de l'utilisation de la distance euclidienne, ce qui reflète une optimisation efficace pour ce type de métrique. Cependant, elle est plus lente avec la distance Manhattan, où sa dépendance aux variations dimensionnelles ralentit le calcul.
- **GFD**, bien qu'efficace dans ses résultats, accuse un temps d'exécution prolongé lorsqu'elle est utilisée avec la distance Minkowski, probablement à cause de la complexité des calculs induite par cette métrique.
- **Zernike** et **Yang** se démarquent par une rapidité constante avec les distances Manhattan et Minkowski, ce qui montre une capacité à s'adapter aux variations métriques. En revanche, leur performance est légèrement plus lente avec la distance euclidienne.
- **ART** est globalement plus lente, en particulier avec la distance euclidienne, où sa complexité algorithmique semble accentuer le temps de traitement. Cependant, elle s'exécute plus rapidement avec Manhattan et Minkowski.

## **5.3 Améliorations pour kmeans**

### **5.3.1 Kmeans++ pour l'Initialisation des Centroids**

L'utilisation de Kmeans++ pour l'initialisation des centroids dans l'algorithme KMeans a montré une amélioration significative par rapport à l'initialisation aléatoire standard. Kmeans++ sélectionne de manière itérative les centroids initiaux en maximisant leur distance les uns des autres, ce qui conduit à une meilleure répartition initiale des clusters et à une convergence plus rapide et plus stable de l'algorithme.

## **5.4 Exploration de Nouvelles Méthodes**

### **5.4.1 Réseaux de Neurones et Deep Learning**

L'application des réseaux de neurones, en particulier des architectures de deep learning, a révolutionné le domaine de la reconnaissance de formes. Ces modèles sont capables de capturer des caractéristiques complexes et de haut niveau à travers des couches cachées, rendant possible la classification précise dans des contextes où les méthodes traditionnelles échouent. Leur capacité à apprendre des représentations de données non linéaires les rend idéaux pour des tâches complexes et variées.

### **5.4.2 Support Vector Machines (SVM)**

Les SVM sont une autre technique puissante, particulièrement efficace dans les tâches de classification binaire. Grâce à leur capacité à maximiser la marge entre différentes classes et à gérer efficacement des espaces de grande dimension, les SVM offrent une approche robuste et précise pour la reconnaissance des formes.

### **5.4.3 Clustering Hiérarchique**

Contrairement aux méthodes de clustering traditionnelles comme kmeans, le clustering hiérarchique offre une vue plus nuancée de la structuration des données. Cette technique construit une hiérarchie de clusters et est particulièrement utile pour visualiser et comprendre la structure des données à différents niveaux d'agrégation.

## **6 Conclusion**

Cette étude approfondie des performances des méthodes appliquées à des modèles knn et kmeans, met en lumière des différences significatives dans leur efficacité et applicabilité dans des contextes de reconnaissance de formes et de clustering.

L'analyse a mis en évidence que chaque méthode présente des avantages et des inconvénients distincts, qui doivent être soigneusement considérés en fonction des objectifs spécifiques de chaque application.